
An exploration of gender biases through a distributional semantics lens



lgbt gay


bisexual

Project Report Presentation Human Language Technologies Università di Trento Cognitive Science Master's 09-02-2024

Biases against marginalised identities in language models have been well-documented, underlying implicit human biases manifesting in language regularities

Retention of voices aligned with hegemonic viewpoints (e.g. inadequately representation of social movements)

Majority of biases analyses focused on binary gender and associated stereotypes



To do: enhance a more accurate and inclusive comprehension of non-binary gender perspective


Non-binary genders encounter obstacles in media representation and access to economic and political opportunities.



- Sample size disparities (lack of understanding);
- Cyclical erasure of gender diversity (misgendering);
- Negative narratives and scarcity of positive gender non-conforming content.

Proposal

Exploratory analysis on embedded contextual representations of a specific set of relevant words in gender studies



CBOW

Cross-language

exploration: English, German, Italian, French, Spanish and Croatian

Embeddings algorithms:

- Word2Vec CBOW (target predicted based on context)
- HAL (co-occurrence patterns with a moving window)


+

Latent Semantic Analysis LSA (term-by-document matrix)

On pre-built semantic spaces trained on WaC, Wikipedia, BNC, OpenSubtitles corpora


English, Italian, German, Spanish, Croatian - CBOW French - HAL


(A) Investigation over the entire spaces [R implementation - LSAfunpackage] neighbours of specific words




(B) Extraction of cross-lingual sub-spaces of specific words: multicosine similarity matrices

[to restrict the focus on discriminatory or lgbtq+ language]:





(C) Sub-spaces - (i) Neighbours to target words(ii) Most similar matrices pairs[Python implementation - interactive code]



Entire semantic spaces:

Extraction of 20 most similar items to target words for each language. Target words: 'man', 'woman', 'female', 'male', 'body', 'sex', 'queer', 'homosexual', 'gender', 'trans- gender'.

Language	Target Term	Neighbors
	'man'	man woman gentleman gray-haired boy person lad men girl stranger
ENG	'woman'	woman girl man divorcée englishwoman lady nymphomaniac prostitute
	'female'	female male cross-dressers incubates polygynous spermatophore male-dominated
	'male'	male female male-to-female sub-adult unringed polygynous african/caribbean lekking
	'body'	body bodies torso corpse limbs incorrupt viscera musculature endoskeleton
	'sex'	sex sexual sexuality homosexual masturbation heterosexual male-male
	'queer'	queer lesbian gay feminist lgbt bisexual trasgender queercore sex-positive herstory
	'homosexual'	homosexual homosexuality sexual heterosexual gay sam-gender pedophilia
	'gender'	gender gendered ethnicity sexuality masculinities race subjectivities racialised
	'transgender'	transgender transgendered lgbt transsexual lesbian bisexual intersex transmen
	'man'	uomo dio vita creatura umano anima donna destino divino amore vivente
ITA	'woman'	donna femminile uomo bambina ragazza madre maschio marito sesso incinto
	'female'	femminile maschile donna giovanile femminista femminilizzazione emancipazione
	'male'	maschile femminile maschio sesso donna mascolinità maschilismo sessuato virile
	'body'	corpo membra corporeo anima eterico chakras prana uomo vivente penetrare
	'sex'	sesso maschio maschile sessuale donna femminile eterosessuale omosessuale erotico
	'queer'	queer lesbian gay cinematic prejudice bigottismo videos coming folk
	'homosexual'	omosessuale gay eterosessuale lesbica sessuale omofobia anti-gay transessuale
	'gender'	genere tipo simile semplicemente spesso piuttosto certo raramente ovvio banale
	'transgender'	transessuale haraway lesbica arcilesbica femminista transex trans ermafrodito cyborg
	'man'	homme esprit âme humain femme père comme mort peuple monde seul humanité
FR	'woman'	femme fille mère jeune mari doeur compagne elle garçon amie maïtresse père princesse
	'female'	feminine femininpersonnalite emitie mariee debuter reussie represente evolue fidele

Sub-spaces with selected words:

80 pairs with the most similar words in the similarity matrices.

In Appendix B (and example): only pairs reporting biases.

Pair	Similarity
Pair: ('djevojka', 'drolja')	0.4782
Pair: ('kurva', 'lezbijka')	0.4694
Pair: ('kurva', 'majka')	0.4428
Pair: ('djevojka', 'prostitutka')	0.3973
Pair: ('drolja', 'lezbijka')	0.3800
Pair: ('drolja', 'majka')	0.3774
Pair: ('dama', 'drolja')	0.3686
Pair: ('grijeh', 'ponos')	0.3518
Pair: ('lezbijka', 'majka')	0.3512

(e) Similarity Pairs in Croatian

Item	Similarity
masculin	0.9298
sexe	0.6835
glamour	0.6500
vogue	0.6211
sexy	0.5963
gay	0.5948
androgyne	0.5867
sexualité	0.5862
sexuel	0.5812
sport	0.5784
imaginaire	0.5693
beauté	0.5688
femme	0.5584
sentimental	0.5425
diable	0.5302
porno	0.5281

French sub-space - Most similar to 'féminine'

'man'	uomo dio vita creatura umano anima donna destino divino amore vivente
'woman'	woman girl man divorcée englishwoman lady nymphomaniac prostitute
'male'	maschile femminile maschio sesso donna mascolinità maschilismo sessuato virile
'female'	female male cross-dressers incubates polygynous spermatophore male-dominated
'queer'	queer lesbian gay feminist lgbt bisexual trasgender queercore sex-positive herstory
'gender'	gender gendered ethnicity sexuality masculinities race subjectivities racialised
'homosexual_a' 'homosexual_b'	homosexuel hétérosexuel pédophile homosexuelle immigré violeur obsédé notoire délinquant travesti drogué célibataire repenti quinquagénaire hétéro polygame
'transgender'	transessuale haraway lesbica arcilesbica femminista transex trans ermafrodito cyborg

Pair	Similarity		
('boyfriend', 'girlfriend')	0.7948	'femme' - 'mère'	0.908
('female', 'male')	0.7899	'fille' - 'mère'	0.907
('feminine', 'masculine')	0.7364	'machisme' - 'misogynie'	0.881
('boy', 'girl')	0.7291	'homophobie' - 'sexisme'	0.866
('father', 'mother')	0.7254	'machisme' - 'sexisme'	0.866
('feminism', 'feminist')	0.7118	'homosexualité' - 'inceste'	0.839
('gay', 'lesbian')	0.6894		
('lesbian', 'lgbt')	0.6545		
('asexual', 'hermaphroditic')	0.6081		
('lgbt', 'transgender')	0.5999		
('nymphomaniac', 'transvesti	te') 0.5590	('dama', 'drolja')	0.3686
'nymphomaniac', 'prostitute'	0.5503		
('lesbianism', 'misogyny')	0.5422	('drolja', 'lezbijka')	0.3800
('misogyny', 'objectification')		('kurva', 'lezbijka')	0.4694
('girl', 'nymphomaniac')	0.5163	('mujer', 'zorra')	0.3850

Sobica 0.3520 maschile donna mosessuale 0.2891 femminista femminista femminista femminista femminista femminista femminista fico femminismo fe	em	Similarity	Item
doma	ansessuale	0.3762	femminile
mosessuale 0.2891 femminista by 0.2886 femminismo mminile 0.2850 sesso avestito 0.2703 maschilismo maginario 0.2655 mascolino aschile 0.2581 sessuale atocoscienza 0.2494 gender adrogino 0.2483 androgino aschilismo 0.2437 genitale ater 0.2436 giovane ater 0.2415 stereotipo sbismo 0.2349 misoginia mminismo 0.2342 immaginario assuale 0.2243 lesbismo assuale 0.2236 transessuale aterotipo 0.2217 transgender ag 0.2185 segregazione attocultura 0.2183 antiviolenza affico 0.2150 sessismo visibile 0.2092 harem	sbica	0.3520	maschile
mminile 0.2850 sesso avestito 0.2703 maschilismo amaginario 0.2655 mascolino aschile 0.2581 sessuale atocoscienza 0.2494 gender adrogino 0.2483 androgino aschilismo 0.2437 genitale adrogino 0.2436 giovane acer 0.2415 stereotipo abismo 0.2349 misoginia amminismo 0.2342 immaginario assuale 0.2236 transessuale and 0.2217 lesbica arereotipo 0.2217 transgender ag 0.2185 segregazione attocultura 0.2183 antiviolenza antiviolenza antiviolenza ffico 0.2150 sessismo omosessuale antiviolenza sessuale 0.2092 harem	emminista	0.3092	donna
mminile 0.2850 sesso avestito 0.2703 maschilismo maginario 0.2655 mascolino aschile 0.2581 sessuale atocoscienza 0.2494 gender adrogino 0.2483 androgino aschilismo 0.2437 genitale ateer 0.2415 stereotipo sbismo 0.2349 misoginia mminismo 0.2342 immaginario assuale 0.2236 transessuale ama 0.2217 lesbica arerotipo 0.2217 transgender ag 0.2185 segregazione attocultura 0.2183 antiviolenza affico 0.2150 sessismo visibile 0.2117 omosessuale sessuale 0.2092 harem	omosessuale	0.2891	femminista
avestito 0.2703 maschilismo amaginario 0.2655 mascolino aschile 0.2581 sessuale atocoscienza 0.2494 gender adrogino 0.2483 androgino aschilismo 0.2437 genitale ater 0.2436 giovane ater 0.2415 stereotipo abismo 0.2349 misoginia amminismo 0.2342 immaginario assuale 0.2243 lesbismo assuale 0.2236 transessuale ama 0.2217 lesbica arerotipo 0.2217 transgender ag 0.2185 segregazione attocultura 0.2183 antiviolenza affico 0.2150 sessismo antiviolenza antiviolenza assessuale antiviolenza antiviolenza antiviolenza sessuale antiviolenza sessismo antiviolenza sessuale antiviolenza sessismo antiviolenza sessuale antiviolenza sessuale	gay	0.2886	femminismo
maginario 0.2655 mascolino aschile 0.2581 sessuale atocoscienza 0.2494 gender adrogino 0.2483 androgino aschilismo 0.2437 genitale ateer 0.2415 stereotipo abismo 0.2349 misoginia amminismo 0.2342 immaginario assuale 0.2243 lesbismo assuale 0.2236 transessuale ama 0.2217 lesbica arereotipo 0.2217 transgender ag 0.2185 segregazione attocultura 0.2183 antiviolenza affico 0.2150 sessismo visibile 0.2117 omosessuale arem	emminile	0.2850	sesso
aschile 0.2581 sessuale gender adrogino 0.2483 androgino aschilismo 0.2437 genitale giovane deer 0.2415 stereotipo sbismo 0.2349 misoginia immaginario destituta 0.2243 lesbismo ssuale 0.2236 transessuale onna 0.2217 lesbica transgender ag 0.2185 segregazione ttocultura 0.2183 antiviolenza ffico 0.2150 sessuale 0.2092 harem	ravestito	0.2703	maschilismo
ntocoscienza olectrogino olect	mmaginario	0.2655	mascolino
achilismo aschilismo 0.2437 genitale deer 0.2436 giovane seer 0.2415 stereotipo sbismo 0.2349 mminismo 0.2342 mminismo 0.2342 ssuale 0.2236 ssuale 0.2236 sereotipo 0.2217 transessuale sereotipo 0.2217 transgender sag 0.2185 segregazione ttocultura ffico 0.2150 visibile 0.2092 harem	naschile	0.2581	sessuale
de	autocoscienza	0.2494	gender
ride 0.2436 giovane neer 0.2415 stereotipo sbismo 0.2349 misoginia mminismo 0.2342 immaginario rostituta 0.2243 lesbismo ssuale 0.2236 transessuale onna 0.2217 tesbica ereotipo 0.2217 transgender rag 0.2185 segregazione ttocultura 0.2183 antiviolenza ffico 0.2150 sessismo visibile 0.2117 omosessuale sessuale 0.2092 harem	androgino	0.2483	androgino
1	naschilismo	0.2437	genitale
sbismo 0.2349 misoginia immaginario ostituta 0.2243 lesbismo transessuale ssuale 0.2236 transessuale lesbica lesbica transgender rag 0.217 transgender segregazione ttocultura 0.2183 antiviolenza sessismo visibile 0.2117 omosessuale harem	oride	0.2436	giovane
mminismo 0.2342 immaginario rostituta 0.2243 lesbismo ssuale 0.2236 transessuale onna 0.2217 lesbica ereotipo 0.2217 transgender rag 0.2185 segregazione ttocultura 0.2183 antiviolenza ffico 0.2150 sessismo visibile 0.2092 harem	ueer	0.2415	stereotipo
rostituta 0.2243 lesbismo ssuale 0.2236 transessuale onna 0.2217 lesbica ereotipo 0.2217 transgender rag 0.2185 segregazione ttocultura 0.2183 antiviolenza ffico 0.2150 sessismo visibile 0.2117 omosessuale sessuale 0.2092 harem	sbismo	0.2349	misoginia
1.216 1.227 1.228 1.22	emminismo	0.2342	immaginario
ssuale 0.2236 transessuale onna 0.2217 lesbica ereotipo 0.2217 transgender rag 0.2185 segregazione ttocultura 0.2183 antiviolenza ffico 0.2150 sessismo visibile 0.2117 omosessuale sessuale 0.2092 harem	rostituta	0.2243	lesbismo
ereotipo 0.2217 transgender sag 0.2185 segregazione ttocultura 0.2183 antiviolenza sessismo visibile 0.2117 omosessuale sessuale 0.2092 harem	essuale	0.2236	transessuale
rag 0.2185 segregazione ttocultura 0.2183 antiviolenza ffico 0.2150 sessismo visibile 0.2117 omosessuale sessuale 0.2092 harem	onna	0.2217	lesbica
ttocultura 0.2183 essismo visibile 0.2193 essisuale 0.217 essisuale 0.2092 essismo ess	tereotipo	0.2217	transgender
ffico 0.2150 sessismo visibile 0.2117 omosessuale sessuale 0.2092 harem	rag	0.2185	segregazione
visibile 0.2117 omosessuale sessuale 0.2092 harem	ottocultura	0.2183	antiviolenza
sessuale 0.2092 harem	affico	0.2150	sessismo
sessuale 0.2092 harem	nvisibile	0.2117	omosessuale
sso 0.2002 prostituzione	isessuale	0.2092	harem
	esso	0.2002	prostituzione

Future directions:

- Navigating complexity in gender diversity;
- Linking with diverse data sources;
- Exploration of pronouns diversity.

Thank you for your attention!

The code is available at:

https://github.com/memonji/gender-biases-exploration.git